TÀI LIỆU KỸ THUẬT SỐ 04 / BỘ 04 TÀI LIỆU TRIỂN KHAI

KẾ HOẠCH THÍ NGHIỆM & ĐO LƯỜNG HIỆU NĂNG

Thiết kế kịch bản kiểm thử từ bản Demo cắm-và-chạy đến đánh giá toàn tuyến trên BIRD, Spider 1.0 và Spider-DK

> **Nguyên tắc tổ chức thí nghiệm:** Để không bị rối khi ghép nhiều mô hình mới cùng lúc, chúng ta thực hiện kiểm thử theo 2 cấp độ: **(1) Kiểm thử từng chặng (Module-Level Ablation)** để chứng minh từng ứng viên ở Agent 1, Agent 2, Agent 3 đều thắng mô-đun cũ của MARS-SQL; và **(2) Kiểm thử toàn tuyến (End-to-End Combos)** bắt đầu từ 3 tổ hợp Demo dễ làm nhất trước khi đo 4 Combo nghiên cứu hoàn chỉnh.

1. Ma Trận Các Tổ Hợp Thử Nghiệm: Từ Bản Demo Đến Bản Hoàn Chỉnh

Ở giai đoạn khởi động, nhóm kỹ thuật lắp ráp và đo đạc **3 Tổ hợp Demo (Demo Combos)** sử dụng các thành phần có sẵn mã nguồn mở, chưa cần can thiệp sâu vào kiến trúc mạng (như LLM-JEPA hay mạng GNN), sau đó nâng cấp lên **4 Tổ hợp Hoàn chỉnh (Full Combos A, B, C, D)**:

Tên Cấu Hình	Lắp Ghép Agent 1	Lắp Ghép Agent 2	Lắp Ghép Agent 3 & Mục Đích Đo
Demo 1 (Baseline ~2.1B)	LitE-SQL (0.6B, chỉ tra cứu vector top-25 cột)	SLM-SQL-1.5B (SFT) + Khóa văn phạm XGrammar	Chỉ dùng bộ lọc 10 quy tắc tĩnh PV-SQL (0 GB). *Kiểm tra tốc độ dựng luồng nhanh nhất trên máy <8 GB RAM.*
Demo 2 (Shared ~3.6B)	NanoJev-0.6B + Thuật toán Cây Steiner tĩnh	FINER-SQL-3B (SFT + RFT) + Khóa XGrammar	PV-SQL + NanoJev-0.6B (Domain SFT dùng chung). *Đo mức tiết kiệm VRAM khi Agent 1 & 3 dùng chung 1 mô hình.*
Demo 3 (High-Perf ~4.0B)	LitE-SQL (0.6B) + Thuật toán Cây Steiner tĩnh	FINER-SQL-3B (Dense GRPO) + Khóa XGrammar	PV-SQL + Laya-421M (kích hoạt Cổng dừng sớm 0.85). *Bản Demo mạnh nhất tiệm cận hiệu năng SOTA.*
Full Combo A / B / C / D	Bổ sung mạng đồ thị Relation-Aware GNN (Combo C, D)	Bổ sung căn chỉnh LLM-JEPA cho 1.5B, 3B và 7B (Combo D)	Đo đối sánh toàn diện với MARS-SQL 21B trên cả 3 tập dữ liệu BIRD, Spider 1.0 và Spider-DK.

2. Thí Nghiệm 1 (Tại Agent 1): Đo Tỷ Lệ Tìm Đúng Cột & Bài Test "48 Câu Mất Bảng Cầu Nối"

Mục tiêu thí nghiệm: Chứng minh rằng tổ hợp siêu nhẹ `LitE-SQL (0.6B) + Cây Steiner (Graph-Link)` không những nhẹ hơn mô hình Grounding 7B của MARS-SQL gấp 11 lần mà còn giải quyết triệt để lỗi đứt gãy đường nối `JOIN`.

Cách tiến hành đo: Chạy độc lập 4 phương án lọc bảng trên toàn bộ tập `BIRD-dev` và tách riêng tập con gồm đúng **48 câu hỏi mà MARS-SQL 21B bị lỗi thiếu bảng cầu nối** Yang et al. (2026):

1. **Phương án 1 (Baseline):** Grounding Agent 7B của MARS-SQL (duyệt từng bảng độc lập).
2. **Phương án 2 (Candidate 1A):** Chỉ dùng LitE-SQL 0.6B lấy top-25 cột theo khoảng cách vector Piao et al. (2026).
3. **Phương án 3 (Candidate 1B - Demo):** LitE-SQL 0.6B ghép với thuật toán Cây Steiner tĩnh trên sơ đồ PK-FK Zhong et al. (2026).
4. **Phương án 4 (Candidate 1B - Full):** LitE-SQL 0.6B + mạng Relation-Aware GNN + Cây Steiner.

Chỉ số nghiệm thu cần ghi nhận:

- **Tỷ lệ thu hồi cột đúng (Schema Linking Recall / TPR):** Mục tiêu đạt **≥ 95.23%** trên BIRD-dev.
- **Tỷ lệ bảo toàn đường nối JOIN trên 48 câu lỗi của MARS-SQL:** Mục tiêu đạt **100%** bảng cầu nối được giữ lại khi bật Cây Steiner, kéo theo độ chính xác thực thi (EX) trên nhóm câu hỏi khó (hard queries) tăng thêm **+13.8%**.

3. Thí Nghiệm 2 (Tại Agent 2): Đo Hiệu Quả Khóa Văn Phạm XGrammar & Căn Chỉnh LLM-JEPA

Mục tiêu thí nghiệm: Đo lường tốc độ và khả năng chặn lỗi cú pháp của động cơ **XGrammar PDA** Dong et al. (2024) so với giải mã tự nhiên và công cụ cũ Outlines, đồng thời kiểm tra mức tăng hiểu biết ngữ nghĩa khi bật **LLM-JEPA** Huang et al. (2026).

Cách tiến hành đo: Cho các mô hình nhỏ (`Qwen3-0.6B` , `SLM-SQL-1.5B` , `CodeS-3B` , `FINER-SQL-3B`) sinh câu lệnh SQL trên cùng một lược đồ rút gọn `S'` ở 3 chế độ: (i) Giải mã tự nhiên không rào chắn (Native), (ii) Dùng thư viện Outlines, và (iii) Dùng động cơ XGrammar PDA (kết hợp có/không có LLM-JEPA). Đối chiếu kết quả với mốc chuẩn thực nghiệm của Chavan (2026):

Hạng Mục Đo Kiểm Tại Agent 2	Giải Mã Tự Nhiên (Native)	Công Cụ Cũ (Outlines CFG)	Mục Tiêu Nghiệm Thu Với XGrammar + LLM-JEPA
Tỷ lệ hợp lệ cấu trúc & kiểu dữ liệu	78.6% – 92.9% (hay sai tên bảng, sai kiểu số/chuỗi)	100% hợp lệ cấu trúc	**100% hợp lệ cấu trúc**; xóa sạch lỗi gõ nhầm tên bảng (như `fprm` vs `frpm`).
Thời gian biên dịch lược đồ CFG	0 ms (không kiểm tra)	Trung bình 2.0 – 4.9 giây (đỉnh điểm tới 19.5 giây)	Chỉ mất **4 – 8 mili-giây** (nhanh hơn Outlines từ 250 đến 1,000 lần).
Mức giảm tốc độ sinh từ (Throughput)	0% (mốc cơ sở)	Giảm 9.0% – 13.0% tốc độ	Chỉ giảm nhẹ **1.6% – 3.7%** tốc độ sinh token.

Hạng Mục Đo Kiểm Tại Agent 2	Giải Mã Tự Nhiên (Native)	Công Cụ Cũ (Outlines CFG)	Mục Tiêu Nghiệm Thu Với XGrammar + LLM-JEPA
Độ chính xác ngữ nghĩa (Khắc phục Hollow Rescue)	Mô hình 1B–3B dễ hiểu sai ý câu hỏi phức tạp	Đúng cú pháp nhưng không tăng khả năng hiểu câu hỏi	Nhờ **LLM-JEPA** (qua 5 seed `{82, 23, 37, 84, 4}`), tăng **+7.8%** trên Spider với 0% chi phí lúc chạy.

4. Thí Nghiệm 3 (Tại Agent 3): Đo Tốc Độ Chấm Điểm 0-Token, Hiệu Chuẩn ECE & Cổng Dừng Sớm

Mục tiêu thí nghiệm: Chứng minh sự kết hợp giữa bộ lọc 10 quy tắc **PV-SQL** Tian & Zhang (2026) và các mô hình quyết định nhanh **System-1** ConvAI (2026) giúp chọn đúng câu lệnh SQL chỉ trong vài mili-giây, biết tự dừng sớm để tiết kiệm vòng lặp và phòng chống được tấn công chèn lệnh độc hại.

Năm kịch bản so sánh trên tập 8 quỹ đạo ứng viên của mỗi câu hỏi:

1. **Bỏ phiếu đa số (Majority Voting):** Chọn câu lệnh có kết quả thực thi xuất hiện nhiều nhất trong 8 lần chạy.
2. **Chỉ dùng PV-SQL (10 quy tắc AST + Probing):** Đo mức tăng điểm hiệu quả thực thi **VES** (mục tiêu đạt **86.9 điểm**, tăng **+20.8%** so với không có PV-SQL; độ chính xác đạt 71.03% trên câu dễ và 54.48% trên câu cực khó).
3. **Kiểm chứng cú sụt giảm ngoài miền (OOD Drop) và hiệu quả Domain SFT trên NanoJev-0.6B:** Chạy thử bản `NanoJev-0.6B` gốc (train trên game) để ghi nhận hiện tượng độ chính xác tụt từ 52.0% xuống **17.0%** khi danh sách ứng viên SQL thay đổi động; sau đó nạp bản `NanoJev-0.6B` đã qua Domain SFT để nghiệm thu mức tăng vọt lên **93.8%** với độ trễ chỉ **~100 ms**.
4. **Đo hiệu chuẩn xác suất và Cổng dừng sớm trên Laya-421M:** Đo tốc độ chấm điểm song song (mục tiêu **~1.2 ms/quyết định** hay ~810 quyết định/giây trên GPU T4), kiểm tra sai số hiệu chuẩn kỳ vọng `ECE ≤ 0.081` (vượt xa Jev 0.246 và CLEF ~0.15), và ghi nhận tỷ lệ % câu hỏi được **Cổng dừng sớm (ngưỡng tự tin `0.85`)** chốt đáp án ngay từ lượt sinh đầu tiên.
5. **Kiểm thử khả năng từ chối đoán mò (Kev-0.8B) & Kiểm thử bảo mật (Red-Teaming):** Đưa vào các bộ ứng viên toàn sai để kiểm chứng `Kev-0.8B` giảm tỷ lệ đoán mò từ 26% xuống **5%** (đạt độ chính xác **98.0%**). Đồng thời, thử chèn chuỗi văn bản độc hại vào ô dữ liệu bảng theo kịch bản của **Wang et al. (2026)** để xác nhận bộ lọc tách biệt dữ liệu ở Bước 4 (Tài liệu 01) chặn đứng hoàn toàn nguy cơ thao túng bộ chấm điểm.

5. Thí Nghiệm 4 (Toàn Tuyến End-to-End): Bảng Chỉ Tiêu Nghiệm Thu Cuối Cùng

Sau khi hoàn tất kiểm thử từng chặng, toàn bộ các cấu hình được chạy đo toàn tuyến trên 3 bộ dữ liệu chuẩn (**BIRD-dev**, **Spider-test** 2,147 mẫu và **Spider-DK**) và đối chiếu trực tiếp với bảng chỉ tiêu nghiệm thu dưới đây:

Hệ Thống / Tổ Hợp	Tổng Tham Số	BIRD-dev EX (%)	Spider-test EX (%)	Độ Trễ TB (Giây/Câu)	Bộ Nhớ VRAM Đỉnh (GB)
MARS-SQL Full (8,8) *(Mốc chuẩn 21B cần thay thế)*	21.0B (3×7B)	77.84%	89.75% (Spider-DK: 78.13%)	22.12s (~13,325 token)	41.0 – 47.0 GB (đồng thời)
MARS-SQL Balanced (4,4)	21.0B (3×7B)	74.90%	—	11.50s	41.0 – 47.0 GB
MARS-SQL Gen-Only (7B) *(Mốc chuẩn 1 mô hình 7B)*	7.0B (1×7B)	66.37%	80.11% (Spider-DK: 69.91%)	Đơn luồng ReAct	~18.5 GB (15.22 GB BF16)
Ứng viên lẻ: SLM-SQL-1.5B	1.5B	**67.08%** (+0.71% vs 7B)	79.06%	Suy luận nhanh	< 8.0 GB RAM
Ứng viên lẻ: FINER-SQL-3B	3.0B	**67.73%** (+1.36% vs 7B)	85.00% (Dev)	**5.57s** (nhanh gấp 4×)	1.93 GB (Q4) / 6.18 GB (F16)
Ứng viên lẻ: LitE-SQL	7.6B (0.6B+7B)	**72.10%**	88.45%	24.98s	~16.5 GB
Combo A (Ultra-Light Edge) *(Mục tiêu nghiệm thu)*	**~2.5B**	**69.5% – 72.0%** (vượt 7B Base)	**83.0% – 85.5%**	**~3.8s – 5.2s**	**< 8.0 GB RAM / CPU** (hoặc ~2.5 GB Q4)
Combo B (Shared System-1) *(Mục tiêu nghiệm thu)*	**~3.6B**	**73.5% – 75.5%** (vượt LitE-SQL 7.6B)	**87.5% – 89.0%**	**~4.5s – 6.2s** (nhanh gấp 4.4×)	**3.2 GB (Q4) – 7.5 GB (F16)** (giảm >83% VRAM)
Combo C (Pareto SOTA) *(Mục tiêu nghiệm thu chính)*	**~4.0B**	**75.0% – 76.8%** (+13.8% câu khó)	**88.5% – 89.5%**	**~4.2s – 5.8s** (giảm 77.4% thời gian)	**3.5 GB (Q4) – 8.5 GB (F16)** (giảm 81%–92% VRAM)
Combo D (High-Accuracy) *(Mục tiêu vượt MARS-SQL 21B)*	**~8.0B**	**> 77.84%** (vượt mốc 21B gốc)	**≥ 89.75%**	**~6.5s – 8.5s**	**< 20.0 GB VRAM** (chạy vừa 1 card 24 GB)

Tài Liệu Tham Khảo

1. Yang, H., et al. (2026). *MARS-SQL: Multi-Agent Reinforcement Learning for Text-to-SQL*. ICML 2026 (arXiv:2511.01008).
2. Piao, S., Lee, J., & Park, S. (2026). *LitE-SQL: A Lightweight and Efficient Text-to-SQL Framework with Vector-based Schema Linking and Execution-Guided Self-Correction*. Findings of EACL 2026 (arXiv:2510.09014).
3. Zhong, J., et al. (2026). *Graph-Link: Bridging the Semantic-Structural Gap in Text-to-SQL via Constrained Subgraph Induction*. ICML 2026.
4. Dong, Y., et al. (2024). *XGrammar: Flexible and Efficient Structured Generation Engine for Large Language Models*. CMU / NVIDIA (arXiv:2411.15100).

5. Huang, H., LeCun, Y., & Balestriero, R. (2026). *LLM-JEPA: Large Language Models Meet Joint Embedding Predictive Architectures*. ICLR 2026 (arXiv:2509.14252).
6. Chavan, A. (2026). *Constrained Decoding Eliminates Structural Failures in Small LLMs but Reveals a Scale-Dependent Semantic Gap*. Preprint (arXiv:2609.23742).
7. Tian, Y., & Zhang, T. (2026). *PV-SQL: Synergizing Database Probing and Rule-based Verification for Text-to-SQL Agents*. Findings of ACL 2026 (arXiv:2604.17653).
8. ConvAI Benchmark Authors (2026). *Laya, CLEF, Kev, and Open System-One Decision Models: ModernBERT Cross-Encoder with RLCD*. Technical Benchmark Reports.
9. Wang, S., et al. (2026). *Hidden Risks of Jev: An Empirical Study of Security, Privacy, and Dual Use*. Preprint (arXiv:2610.04985).